

Universidade Federal da Paraíba  
Centro de Informática — Departamento de Informática  
Disciplina: Aprendizado Profundo — Período 2026.1  
Professor: Tiago Maritan

# Lista de Exercícios — Resolução Completa

Redes MLP, CNN e Autoencoders

Este relatório apresenta a resolução completa da lista de exercícios da disciplina de Aprendizado Profundo, contemplando a implementação de Redes Perceptron de Múltiplas Camadas (MLP), Redes Neurais Convolucionais (CNN) e Autoencoders, aplicados a problemas de regressão e classificação sobre diferentes bases de dados (função polinomial sintética, California Housing, Titanic e Fashion-MNIST).

Nota metodológica: devido às limitações de hardware do ambiente de execução (processamento em CPU única, sem GPU), alguns experimentos com redes profundas (CNNs e Autoencoders sobre o Fashion-MNIST) foram realizados utilizando subconjuntos representativos dos dados de treino/teste e um número reduzido de épocas, suficientes para demonstrar a metodologia, convergência do treinamento e todas as análises solicitadas. Os códigos completos são fornecidos em arquivos .py separados e podem ser re-executados com o dataset completo caso haja disponibilidade de GPU.

## Questão 1 — Redes MLP para Regressão

### 1(a) Aproximação de função polinomial

Foi implementada uma MLP (arquitetura 64-64-32 neurônios, ativação ReLU, otimizador Adam) para aproximar a função  $f(x) = 10x^5 + 5x^4 + 2x^3 - 0,5x^2 + 3x + 2$ , no intervalo  $0 \leq x \leq 5$ . Foram gerados 2000 pontos aleatórios no domínio, divididos em 80% treino / 20% teste. As entradas e saídas foram padronizadas (StandardScaler) antes do treinamento, e 15% do conjunto de treino foi reservado para validação (early stopping).

| Métrica | Valor (conjunto de teste) |
|---------|---------------------------|
| MAE     | 21.69                     |
| MSE     | 1340.05                   |
| RMSE    | 36.61                     |

Considerando que  $f(x)$  atinge valores da ordem de  $3,5 \times 10^4$  em  $x=5$ , o erro absoluto médio ( $\approx 21,7$ ) representa menos de 0,1% da escala da função, indicando uma boa aproximação.




Figura 1a.1 — Função real vs. função aproximada pela MLP.




Figura 1a.2 — Curva de erro de treinamento (loss).




Figura 1a.3 — Curva de erro de validação ( $1 - R^2$ ).




Figura 1a.4 — Dispersão entre valores reais e preditos no conjunto de teste.

## 1(b) California Housing Dataset

Para este item foi utilizada uma base equivalente ao California Housing Dataset (mesmas variáveis: localização geográfica, idade média dos imóveis, número de cômodos/quartos, população, número de domicílios, renda média e valor médio dos imóveis, além do atributo categórico de proximidade ao oceano).

### Análise exploratória e tratamento dos dados

- 207 valores ausentes na variável `total_bedrooms`, tratados por imputação da mediana.
- Criação de atributos derivados: cômodos por domicílio, proporção quartos/cômodos e pessoas por domicílio, comumente informativos neste problema.
- Variável categórica `ocean_proximity` codificada via One-Hot Encoding.
- Todas as variáveis numéricas padronizadas (`StandardScaler`), incluindo a variável-alvo.




Figura 1b.1 — Matriz de correlação entre as variáveis numéricas.




Figura 1b.2 — Distribuição do valor médio dos imóveis (variável-alvo).




Figura 1b.3 — Distribuições das variáveis explicativas.




Figura 1b.4 — Distribuição geográfica do valor dos imóveis (mapa de dispersão lon/lat).

## Arquitetura e resultados

Rede MLP com camadas ocultas de 128, 64 e 32 neurônios, ativação ReLU, otimizador Adam, com early stopping (15% do treino para validação).

| Métrica | Valor (conjunto de teste) |
|---------|---------------------------|
| MAE     | US\$ 36,325               |
| MSE     | $3.11 \times 10^9$        |

|      |             |
|------|-------------|
| RMSE | US\$ 55,807 |
|------|-------------|




Figura 1b.5 — Curva de erro de treinamento.




Figura 1b.6 — Curva de erro de validação.




Figura 1b.7 — Valores reais vs. preditos no conjunto de teste.



## Questão 2 — MLP para Classificação (Titanic)

O objetivo é prever a sobrevivência de passageiros do Titanic a partir de atributos demográficos e socioeconômicos, utilizando uma base equivalente à disponibilizada no Kaggle (mesmas variáveis: classe, sexo, idade, tarifa, porto de embarque, etc.).

### Análise exploratória

- 891 passageiros; 38,4% sobreviventes e 61,6% não sobreviventes (classes moderadamente desbalanceadas).
- Valores ausentes: age (177 registros), embarked (2 registros), deck (688 registros — quase 77% ausente).




Figura 2.1 — Distribuição das classes (sobreviveu / não sobreviveu).




Figura 2.2 — Sobrevivência por sexo, classe socioeconômica e idade.

### Tratamento de dados e atributos

- Coluna deck removida (77% de valores ausentes).
- Colunas alive e class removidas por serem redundantes com survived e pclass, respectivamente; adult\_male removido por ser redundante com sexo/idade (who); embark\_town removido por redundância com embarked.
- Valores ausentes em age imputados pela mediana; embarked imputado pela moda.
- Criado o atributo derivado family\_size = sibsp + parch + 1.
- Atributos categóricos (pclass, sex, embarked, who, alone) transformados via One-Hot Encoding; atributos numéricos padronizados (StandardScaler).

- Balanceamento de classes: sobreamostragem (oversampling) da classe minoritária (sobreviventes) no conjunto de treino, igualando-a à classe majoritária.

## Arquitetura e resultados

MLP com camadas ocultas de 64 e 32 neurônios, ativação ReLU, otimizador Adam, com early stopping.

| Métrica   | Valor (conjunto de teste) |
|-----------|---------------------------|
| Accuracy  | 81.0%                     |
| Precision | 75.4%                     |
| Recall    | 75.4%                     |
| F1-score  | 75.4%                     |




Figura 2.3 — Curva de erro de treinamento.




Figura 2.4 — Curva de erro de validação.




Figura 2.5 — Matriz de confusão no conjunto de teste.

### Questão 3 — Fashion-MNIST: MLP vs. CNN

Foram implementados dois classificadores para o Fashion-MNIST (10 classes de peças de vestuário): uma MLP totalmente conectada e uma CNN. Por limitação de hardware (CPU única), o treinamento utilizou um subconjunto de 12.000 imagens de treino, 2.000 de validação e 2.000 de teste, amostrados aleatoriamente e de forma estratificada pela própria aleatoriedade do dataset original.

#### Arquiteturas

- MLP:  $784 \rightarrow 256 \rightarrow 128 \rightarrow 10$ , ativação ReLU, dropout 0.2, otimizador Adam, 15 épocas.
- CNN:  $\text{Conv}(1 \rightarrow 16, 3 \times 3) \rightarrow \text{MaxPool} \rightarrow \text{Conv}(16 \rightarrow 32, 3 \times 3) \rightarrow \text{MaxPool} \rightarrow \text{FC}(1568 \rightarrow 128) \rightarrow \text{FC}(128 \rightarrow 10)$ , ativação ReLU, dropout 0.3, otimizador Adam, 10 épocas.

| Modelo | Acurácia no teste |
|--------|-------------------|
| MLP    | 85.75%            |
| CNN    | 86.10%            |

A CNN obteve acurácia ligeiramente superior à MLP mesmo com menos épocas de treinamento, evidenciando a vantagem das camadas convolucionais em capturar padrões espaciais locais (bordas, texturas) relevantes para classificação de imagens.




Figura 3.1 — MLP: curva de erro de treinamento e validação.




Figura 3.2 — MLP: matriz de confusão.




Figura 3.3 — CNN: curva de erro de treinamento e validação.




Figura 3.4 — CNN: matriz de confusão.

## Questão 4 — Interpretabilidade da CNN

### 4(a) Filtros da primeira camada convolucional




Figura 4.1 — Os 16 filtros  $3 \times 3$  aprendidos pela camada conv1.

Os filtros aprendidos na primeira camada convolucional funcionam predominantemente como detectores de bordas e gradientes de intensidade em diferentes orientações (horizontal, vertical e diagonal), além de alguns filtros que respondem a regiões de textura mais uniforme. Esse comportamento é esperado para a primeira camada de uma CNN treinada sobre imagens em escala de cinza, já que é nela que a rede aprende os elementos visuais mais elementares.

### 4(b) Mapas de ativação (camada intermediária conv2)

Foram selecionadas 5 imagens do conjunto de teste. Para cada uma, são exibidos os 6 canais de ativação mais relevantes da segunda camada convolucional (conv2).




Figura 4.2 — Mapas de ativação (conv2) para o exemplo 1.




Figura 4.3 — Mapas de ativação (conv2) para o exemplo 2.




Figura 4.4 — Mapas de ativação (conv2) para o exemplo 3.




Figura 4.5 — Mapas de ativação (conv2) para o exemplo 4.




Figura 4.6 — Mapas de ativação (conv2) para o exemplo 5.

De forma geral, os mapas de ativação da camada conv2 realçam contornos e regiões de alto contraste das peças de vestuário (silhueta, gola, mangas, alças), indicando que a rede já combina as bordas simples detectadas na primeira camada em padrões espaciais mais estruturados e discriminativos entre as classes.

#### 4(c) Exemplos corretos e incorretos





Figura 4.7 — Exemplos corretamente classificados (classe real, classe predita e probabilidade).





*Figura 4.8 — Exemplos classificados incorretamente pela CNN.*

Os erros de classificação concentram-se, em geral, em classes visualmente semelhantes entre si (por exemplo, entre "Shirt", "Pullover", "Coat" e "T-shirt/top"), o que é consistente com a matriz de confusão apresentada na Questão 3, na qual essas classes concentram a maior parte das trocas.

## Questão 5 — Autoencoders

### 5(a) Autoencoder convolucional com diferentes espaços latentes

Foi implementado um autoencoder convolucional (encoder: duas camadas Conv2D com stride 2; decoder: duas camadas ConvTranspose2D), treinado em três versões com espaços latentes de dimensão 8, 32 e 64.

| Dimensão do espaço latente | MSE médio de reconstrução (teste) |
|----------------------------|-----------------------------------|
| 8                          | 0.0335                            |
| 32                         | 0.0180                            |
| 64                         | 0.0160                            |

Como esperado, o erro de reconstrução diminui à medida que o espaço latente aumenta, pois mais informação da imagem original pode ser preservada na representação comprimida. O ganho de qualidade entre 32 e 64 dimensões é, no entanto, proporcionalmente menor do que o ganho entre 8 e 32, sugerindo retornos decrescentes a partir de determinado tamanho latente.




Figura 5.1 — Curvas de erro de treinamento para os três tamanhos de espaço latente.




Figura 5.2 — Comparação visual: imagens originais (linha superior) e reconstruções para espaços latentes de 8, 32 e 64 dimensões (linhas seguintes), para 10 imagens do conjunto de teste.

## 5(b) Denoising Autoencoder

Foi adicionado ruído gaussiano (fator 0,4, com recorte para o intervalo  $[0,1]$ ) às imagens de entrada, e um novo autoencoder (espaço latente = 32) foi treinado para reconstruir as imagens originais (limpas) a partir das versões ruidosas.

| Métrica                                             | Valor  |
|-----------------------------------------------------|--------|
| MSE médio de reconstrução (teste, vs. imagem limpa) | 0.0209 |




Figura 5.3 — Curva de erro de treinamento do denoising autoencoder.




Figura 5.4 — Para as mesmas 10 imagens de teste: originais (linha 1), versões ruidosas (linha 2) e reconstruções produzidas pelo denoising autoencoder (linha 3).

O denoising autoencoder consegue remover grande parte do ruído gaussiano adicionado, recuperando a forma geral das peças de vestuário, embora com alguma perda de detalhes finos — comportamento esperado, já que o modelo aprende a priorizar os padrões estruturais mais robustos presentes nos dados de treino em detrimento de ruído de alta frequência.

### Considerações finais

Todas as questões da lista foram implementadas e avaliadas conforme solicitado. Os códigos-fonte completos (Python) de cada exercício, os dados utilizados e as figuras geradas estão organizados e disponibilizados juntamente com este relatório.

Nota sobre escala dos experimentos: em razão do ambiente de execução dispor de apenas uma CPU (sem GPU) e memória limitada, os experimentos das Questões 3, 4 e 5 (que envolvem CNNs e autoencoders sobre o Fashion-MNIST) foram realizados com subconjuntos de dados e número reduzido de épocas. Isso foi suficiente para obter modelos com desempenho satisfatório (acurácia  $>85\%$  na classificação, reconstrução consistente nos autoencoders) e para produzir todas as análises qualitativas e quantitativas solicitadas. Caso os grupos apresentem a lista com acesso a GPU, recomenda-se re-executar os scripts fornecidos com o dataset completo (60.000 imagens de treino) e mais épocas para obter métricas ainda mais robustas.